ADR-001: Uso de RAG en el proyecto

Estado

Aceptado

Contexto

El sistema requiere responder consultas sobre un corpus de conocimiento técnico interno (gestión de secretos, seguridad, despliegue, observabilidad, chunking y evaluación). Este conocimiento no forma parte de los datos de entrenamiento de modelos públicos y debe poder actualizarse de forma continua e independiente sin reentrenar un modelo. Además, el negocio requiere trazabilidad auditada con citación explícita de fuentes.

Alternativas

1. **Sin LLM**: Búsqueda por palabras clave sin generación de respuestas sintéticas en lenguaje natural. No cumple el objetivo de experiencia conversacional.
2. **LLM sin RAG**: El modelo respondería con conocimiento desactualizado o propenso a alucinaciones, sin posibilidad de verificar fuentes.
3. **RAG (Retrieval-Augmented Generation)**: Combina una etapa de recuperación (lexical, vectorial o híbrida) con inyección de contexto acotado y generación condicionada.
4. **Agente con herramientas (Tool Calling)**: Mayor latencia y complejidad operativa no justificada para una base de conocimiento documental estática/semiestática.

Evidencia

- **Golden set**: 12 casos de validación (10 con fuente esperada + 2 casos sin evidencia para verificar abstención).
- **Hit@K**:
- Local (hash, top-5): 10/10 = 100%.
- Azure AI Search (keyword, top-5): 10/10 = 100%.
- Azure AI Search (vector hash, top-5): 8/10 = 80%.
- Azure AI Search (híbrido RRF, top-5): 8/10 = 80%.
- **Latencia**:
- Local: ~1.0 ms promedio.
- Azure AI Search Free: ~1050 ms promedio.
- **Riesgos**:
- Indirect prompt injection desde documentos maliciosos (mitigado con delimitadores `DOCUMENTO NO CONFIABLE` y escaneo de patrones).
- Alucinaciones ante preguntas fuera de corpus (mitigado con umbral de relevancia y respuesta formal de abstención).
- **Costo**:
- Azure AI Search en SKU Free (0 USD en Azure for Students).
- Generación extractiva local o con Ollama (0 USD de costo cloud).

Decisión

Se adopta **RAG con Azure AI Search e integración híbrida**, manteniendo compatibilidad con almacenamiento local en memoria para pruebas y desarrollo.

Consecuencias

- Requiere pipeline de indexación y sincronización de chunks ante cambios en el corpus.
- Introduce latencia adicional por el paso de retrieval (~1 s en Azure).
- Exige aislar documentos recuperados como datos no confiables para prevenir vulnerabilidades de seguridad.

Condición para revertir la decisión

Si el corpus se vuelve extremadamente voluminoso superando la cuota Free sin presupuesto para SKU pagado, o si la latencia promedio supera los 3000 ms degradando la experiencia de usuario.