Experiment Log - RAG

Fecha	Cambio	Hipotesis	Metrica	Resultado	Decision
2026-10-12	chunk_size=900, overlap=120	Baseline de fragmentación para documentos técnicos	Hit@5	Hit@5 = 100% en backend local	Mantener configuración base
2026-10-12	top_k=5	Un top_k=5 balancea cobertura de evidencia y latencia	Hit@5 / latencia	10/10 hits, latencia local ~1 ms	Mantener top_k=5
2026-10-12	Modo Keyword (Azure AI Search)	Búsqueda lexical BM25 efectiva para terminología técnica exacta	Hit@5 / latencia	Hit@5 = 10/10 (100%), latencia 1037 ms	Seleccionar como modo primario con hash embeddings
2026-10-12	Modo Vector (Azure AI Search)	Búsqueda con hash embedding (128 dims)	Hit@5 / latencia	Hit@5 = 8/10 (80%), latencia 1018 ms	Degradación esperada por falta de semántica en hash
2026-10-12	Modo Hybrid (Azure AI Search)	Fusión RRF (BM25 + vector hash)	Hit@5 / latencia	Hit@5 = 8/10 (80%), latencia 1087 ms	Mantener disponible; requiere embeddings semánticos para superar a keyword
2026-10-12	Prueba de seguridad adversaria	Inyección indirecta contenida en chunks con etiquetas no confiables	Security flags / contención	5 flags detectadas, respuesta extractiva no manipulada	Mantener pipeline de sanitización